



(12) 发明专利申请

(10) 申请公布号 CN 122201305 A

(43) 申请公布日 2026. 06. 12

(21) 申请号 202610254572.5

(22) 申请日 2026.03.04

(71) 申请人 王奕川

地址 518000 广东省深圳市宝安区海乐路8号1000

(72) 发明人 王奕川

(51) Int. Cl.

G10L 15/26 (2006.01)

G10L 15/16 (2006.01)

G10L 21/0208 (2013.01)

G10L 15/22 (2006.01)


权利要求书2页 说明书20页 附图1页

(54) 发明名称

一种离线连续语音转写与动态替换方法及电子设备

(57) 摘要

本发明公开了一种离线连续语音转写与动态替换方法及电子设备,旨在解决端侧语音识别无法兼顾低延迟与高精度的固有矛盾。该方法在纯本地环境下运行,将音频流动态切片后分发至异步双轨:快速处理链路率先生成初始草稿并输出至显示区域,消除视觉延迟;深度推理链路并行执行深度推理,结合权限分级的内存词库后处理与相邻切片边界去重,生成高精度定稿文本。随后,系统利用时间戳与屏幕坐标锚定,调用底层指令将显示区域的草稿无缝全量替换为定稿,并辅以基于算力状态的界面(UI)动态联动。本发明突破了端侧算力瓶颈,实现了极低视觉延迟与极高精度结果并存的交互体验。



1. 一种离线连续语音转写与动态替换方法,应用于具有本地计算能力的终端,所述方法在无需与外部服务器进行数据通信交互的本地环境下独立运行,其特征在于,所述方法包括以下步骤:

- a. 音频获取:响应于语音输入指令,在所述终端本地获取音频流数据;
- b. 第一级转写:将所述音频流数据输入至本地部署的第一语音处理模块,以第一响应延迟生成第一转录文本,并将所述第一转录文本输出至所述终端的显示区域;
- c. 第二级转写:将所述音频流数据输入至本地部署的第二语音处理模块,以第二响应延迟生成第二转录文本;其中,所述第二响应延迟大于所述第一响应延迟;
- d. 比对与替换:根据所述第二转录文本,对所述显示区域中与所述第一转录文本对应的部分进行比对与替换,输出最终的连续转录文本。

2. 根据权利要求1所述的方法,其特征在于,在所述步骤a中,具体包括以下步骤:将获取的所述音频流数据切分为多个音频切片。

3. 根据权利要求2所述的方法,其特征在于,所述切分为多个音频切片的触发条件包括以下至少一种:

第一触发条件:检测到语音停顿的持续时间达到第一预设时间阈值;

第二触发条件:当前音频切片的持续时间达到第二预设时间阈值。

4. 根据权利要求1所述的方法,其特征在于,所述第一语音处理模块为基于概率统计模型或轻量级神经网络的声学特征提取模型,所述轻量级神经网络包括循环神经网络、卷积神经网络或包含自注意力机制的流式解码网络模型;所述第二语音处理模块为用于进行全局深层语义建模且包含注意力机制的神经网络模型。

5. 根据权利要求1所述的方法,其特征在于,在所述步骤c之后,所述步骤d之前,还包括对所述第二转录文本进行词库映射的步骤:

调用本地部署的预设基础词库及用户自定义词库;

将所述步骤c生成的第二转录文本与所述预设基础词库及用户自定义词库进行字符或词汇比对;

若比对命中,则根据预设的权重分配逻辑,利用命中的词汇替换所述第二转录文本中的对应字符或词汇序列,并将替换后的文本作为执行所述步骤d的最终第二转录文本。

6. 根据权利要求1所述的方法,其特征在于,在所述步骤d中,所述对显示区域中对应部分进行替换的操作,具体通过以下至少一种执行方式实现:

第一种方式为全量覆盖:向所述终端的显示区域发送删除或清除指令,将对应于所述第一转录文本的全部字符序列予以删除,并输出所述第二转录文本;

第二种方式为差异抹除:定位所述第一转录文本与所述第二转录文本之间的差异字符片段,仅对所述差异字符片段执行定向删除与新字符写入。

7. 根据权利要求2所述的方法,其特征在于,在所述生成最终的连续转录文本的过程中,还包括针对相邻音频切片的边界去重步骤:

提取相邻的上一音频切片所对应转录文本的尾部字符序列,以及当前音频切片所对应转录文本的头部字符序列;

计算所述尾部字符序列与所述头部字符序列的字符重叠度;

当所述字符重叠度满足预设重叠条件时,在所述最终的连续转录文本中,剔除冗余的

重叠字符序列。

8. 根据权利要求2所述的方法, 其特征在于, 所述方法还包括基于算力负载状态的界面交互步骤:

实时监测所述第二语音处理模块中未完成处理的待处理音频切片数量;

当所述待处理音频切片数量超过预设的队列积压阈值时, 在所述终端界面触发并输出处理积压提示信息;

响应于语音输入结束指令, 若所述第二语音处理模块中仍存在待处理音频切片, 则在所述终端界面动态输出处理进度提示信息;

当所有待处理音频切片均完成相应的所述比对与替换操作后, 在所述终端界面输出处理完成的状态标识。

9. 根据权利要求1所述的方法, 其特征在于, 所述具有本地计算能力的终端包括以下至少一种设备: 智能手机、计算机设备、具备独立处理芯片的麦克风音频外设。

10. 一种电子设备, 其特征在于, 包括:

至少一个处理器; 以及,

与所述至少一个处理器通信连接的存储器;

其中, 所述存储器存储有可被所述至少一个处理器执行的计算机指令, 所述计算机指令被所述至少一个处理器执行时, 使得所述电子设备能够实现上述权利要求1至9中任一项所述的方法。

一种离线连续语音转写与动态替换方法及电子设备

技术领域

[0001] 本发明涉及人工智能与人机交互技术领域,尤其涉及一种端侧边缘计算场景下的离线连续语音转写与动态替换方法及电子设备。

背景技术

[0002] 随着人工智能技术的发展,语音输入已成为智能终端(如智能手机、计算机、可穿戴设备等)的重要人机交互方式。目前,主流的连续语音转写技术主要分为“云端识别方案”与“端侧离线识别方案”两种路径,但这两种路径在实际应用中均存在亟待解决的技术瓶颈:

[0003] 云端识别方案的局限性:高度依赖稳定的网络连接,在弱网、无网环境下无法工作;且用户的语音数据必须持续上传至云端服务器,存在潜在的数据泄露风险与隐私安全隐患,难以满足高私密场景的需求。

[0004] 端侧离线识别方案的固有矛盾:在完全离线的本地算力环境下,语音识别的“低延迟(实时上屏)”与“高准确率”之间存在着难以调和的矛盾。传统轻量级离线模型虽具备流式输出能力,但识别精度受限;而端侧深度神经网络大模型虽具备高精度,但推理耗时较长,导致界面长时间无文本输出或视觉反馈严重滞后。

[0005] 长音频内存溢出与硬切分的拼接缺陷:端侧大模型在处理长音频时,极易因特征矩阵膨胀引发内存溢出(Out Of Memory, OOM)与系统进程阻塞。为防止崩溃,行业内通常对音频流进行强制切片。然而,传统的切分方式不可避免地会割裂语义,导致相邻切片的转录结果在拼接时出现大量重复的“回音”字符或错误的断句,严重破坏了连续输出的平滑度。

[0006] 综上所述,如何在无网的端侧环境下,突破端侧算力瓶颈,既能为用户提供低延迟的视觉反馈,又能保证最终文本的高准确率,并有效消除切片拼接带来的冗余错误与界面停滞感,是本领域亟待解决的核心技术问题。

发明内容

[0007] 本发明的目的在于提供一种离线连续语音转写与动态替换方法及电子设备,旨在解决现有端侧离线语音识别技术中,无法兼顾“低延迟实时反馈”与“高精度上下文纠错”的矛盾,从而在纯本地算力环境下,提供平滑且高精度的语音交互体验。

[0008] 为了实现上述目的,本发明提供了一种离线连续语音转写与动态替换方法,应用于具有本地计算能力的终端,所述方法在无需与外部服务器进行数据通信交互的本地环境下独立运行,所述方法包括:

[0009] 音频获取与切片:响应于语音输入指令,在本地获取音频流数据,并基于动态阈值条件将其切分为多个音频切片。

[0010] 异步双轨并发(快轨与慢轨):将所述音频流数据输入至本地部署的第一语音处理模块,以第一响应延迟生成第一转录文本并快速输出至终端的显示区域;同时,将所述数据

输入至本地部署的第二语音处理模块,以大于第一响应延迟的第二响应延迟生成高精度的第二转录文本。

[0011] 多级词库后处理干预:在慢轨输出后,调用本地预置基础词库及用户自定义词库进行比对,若比对命中,则根据权限权重进行词库映射与强制替换。

[0012] 边界去重缝合:提取相邻音频切片对应转录文本的首尾字符序列,计算重叠度,并在最终连续转录文本中剔除冗余的重叠字符。

[0013] 底层指令定向替换:利用时间戳等锚定机制,根据所述第二转录文本,对显示区域中由第一转录文本占据的对应部分进行底层的全量覆盖或差异抹除替换。

[0014] 算力状态联动交互:实时监测后台处理积压情况,动态在终端界面输出处理积压提示或进度信息;并在所有切片处理完毕后,输出处理完成的状态标识,完成无感视觉闭环。

[0015] 此外,本发明还提供了一种电子设备,包括:至少一个处理器;以及,与所述至少一个处理器通信连接的存储器;其中,所述存储器存储有可被所述至少一个处理器执行的计算机指令,所述计算机指令被执行时,使得所述电子设备能够实现上述的离线连续语音转写与动态替换方法。该电子设备可表现为通用智能移动终端(复用本地CPU/NPU),或具备独立处理芯片与物理隐私隔离特性的智能麦克风外设。

[0016] 有益效果

[0017] 与现有技术相比,本发明实施例提供的方法及电子设备,具备以下显著的有益效果:

[0018] 突破“算力与体验”的固有矛盾,重构交互范式:通过“异步双轨转写与动态视觉替换”机制,利用小模型提供极低延迟的“流式草稿”上屏,利用大模型在后台进行“异步精准后处理”并执行无感替换。巧妙利用了人眼的阅读时间差,实现了“极低视觉延迟、极高结果精度”的流畅交互体验。

[0019] 根除端侧长语音OOM崩溃,实现长时续航:通过动态双重阈值切片机制配合极致的内存接力调度,系统后台的内存占用量基本与录音总时长解耦,使得终端设备在纯离线状态下能够稳定支持长达数小时的不间断连续转写。

[0020] 极高的数据隐私与全天候可用性:全流程在本地物理沙盒内闭环完成,有效规避了敏感语音数据的云端泄露风险,确保设备在无网或弱网环境下依然能正常运作。

[0021] 有效消除切片带来的“拼接回音”:引入FuzzyMatch相邻切片边界去重逻辑,自动剔除冗余重叠字符,有效衔接了因VAD或强制切分导致的语义断层。

[0022] 权限分级的瀑布式词库干预:创新性地构建了基础白名单与VIP热词的层级干预机制,有效弥补了量化大模型在专有名词上的识别偏差,防范了生僻词库对高频词的大面积误判。

[0023] 提供状态感知的动态交互闭环:通过软硬件联动的算力仪表盘与进度提示,将后台底层黑盒的计算延迟转化为柔性、透明的UI视觉反馈,有效避免了因状态未知导致的用户误操作与过度等待。

附图说明

[0024] 本发明的上述方面和优点从结合下面附图对具体实施方式的描述中将变得明显

和容易理解,其中:

[0025] 图1是本发明实施例提供的一种离线连续语音转写与动态替换方法的宏观架构与核心数据流向示意图;该图直观示出了从音频获取、中央处理器分发、异步双轨并行处理(产生处理时延差异),直至最终通过触发底层全量替换指令,使显示区域内的初稿完成视觉平滑过渡并输出定稿文本的全链路执行逻辑。

具体实施方式

[0026] 为使本发明的目的、技术方案、有益效果以及所能实现的优点能够更加清晰、透彻地被理解和实施,下面将结合附图对本发明的具体实施方式进行详细说明。需要理解的是,附图仅用于说明本发明的示例性实施方式,而非对其构成任何形式的限定。在所有附图中,相同的附图标记通常表示相同或相似的部件,以便于阅读和理解。同时应理解,附图所示的逻辑流程或模块架构仅为优选的完整链路,其中的各个子步骤或子模块均可根据不同的应用场景被独立提取或重新组合,构成独立的技术方案。

[0027] 本领域的普通技术人员应当理解,本文所描述的具体实施方式旨在深入解释本发明的核心架构。本发明的基础保护客体,是一种基于处理时延差异与内存空间调度的“异步双轨处理与动态视觉替换”系统宏观架构。因此,在不脱离本发明核心架构与精神的情况下,本领域技术人员对本文中提及的任何具体实施手段进行各种修改、组合、部分替换或等同替换(例如:但不限于替换不同的切分算法、采用不同框架的第一和第二语音处理模块(如声学或语言模型)、替换提取首尾字符进行拼接去重的匹配算法、以及采用不同的底层UI替换调度API等),均应被视为落入本发明宏观架构的保护范围之内。

[0028] 特别需要声明的是,尽管本发明具备上述宏观架构的包容性,但在后续实施例中,为实现该架构所列举的各项具体且优选的算法逻辑(例如:针对相邻切片的特定重叠度匹配算法、多级词库的动态权重干预逻辑等),作为支撑该架构达成流畅交互体验的关键技术节点,其自身同样具备独立的创造性与技术价值。申请人保留将这些特定的核心算法与处理逻辑,作为独立的技术方案提出申请的权利。

[0029] 此外,本发明实施例所提供的方法及系统,广泛应用于具有本地计算能力的终端设备。目前的典型实施载体包括但不限于智能手机、计算机设备,以及高度集成了独立算力芯片的麦克风音频外设等。应理解,随着边缘计算与智能硬件的飞速演进,未来势必会涌现出形态各异的智能电子设备。无论这些设备的物理外观如何改变、搭载何种底层的操作系统,抑或是应用于何种未知的交互场景,只要该设备内部部署并执行了本发明所述的“异步双轨转写与动态视觉替换”的核心逻辑,均应落入本发明的保护范围之内。同时,针对特定硬件实体(如纯硬件闭环的智能麦克风外设)所定制的独立内存隔离与芯片调度机制,亦构成可独立保护的实体设备方案。

[0030] 关于系统架构普适性的说明:

[0031] 需要说明的是,本发明所提出的上述异步双轨架构与动态替换逻辑,其核心创新本质是一种“基于处理时延差异的交替上屏与视觉平滑替换交互机制”。因此,该核心架构自身具备彻底超越底层硬件物理分布与算力部署位置的独立普适性。

[0032] 应理解,本发明的核心思想在于其时间维度上的任务调度与UI呈现逻辑,而非空间维度上的算力存放点。无论实施该架构的应用程序或系统采用何种部署形态——无论是

“快慢双轨均部署于本地终端”、“快轨部署于本地而慢轨依托于云端”,还是“快慢双轨均完全部署于云端服务器(仅向本地终端下发流式草稿与滞后的定向替换指令)”——只要其在宏观交互上完整执行了“极速初始转写上屏→异步高精度转写推理→差异化比对与动态UI替换”这一时间差调度工作流,该工作方式在本质上均使用了本发明所首创的核心交互架构。申请人保留将此跨越物理部署位置限制的异步交替交互架构,作为独立技术方案提出申请的权利。

[0033] 关于优选实施例边界的说明:

[0034] 尽管上述广义交互架构完全兼容并涵盖了云端或端云协同的算力部署,但考虑到特定的高端商业应用场景(如机密会议、个人极度隐私保护、商业秘密谈判等)对数据绝对安全的严苛要求,任何形式的网络连接与音频外传节点均构成潜在的数据泄露敞口,无法满足极高级别的物理隔离要求。

[0035] 因此,为了解决纯端侧设备在有限内存(RAM)与算力瓶颈下无法持久运行大模型的固有矛盾,在本发明的一个优选实施例(即当前权利要求书的核心保护场景)中,所述方法与系统被严格限定在“无需与外部服务器进行任何数据通信交互的纯本地环境”下独立运行。

[0036] 在该优选实施例的完整生命周期内,系统在任何工作状态下均被绝对物理(或软件级)切断与外部广域网的数据交互。这意味着,本发明的目标系统天生摒弃了一切依赖云端算力的混合机制。所有的音频流采集、双轨模型并发推理、多级词库后处理、乃至数十上百分钟超长连续语音的切片销毁与UI无感替换,完全被强制闭环且物理隔离在终端设备的本地沙盒内部。该优选实施例旨在克服现有“云端/离线混合双模”或“纯云端”技术对网络通信链路的刚性依赖,致力于在完全断网的纯本地环境中建立安全、可靠的交互体验。

[0037] 基于上述广义交互架构原则与纯本地优选实施例的严格界定,下面将分节详细描述本发明系统在纯离线孤岛环境下的具体实施流程:

[0038] 第一节 音频获取

[0039] 1.1 音频获取的触发与基础数字化原理

[0040] 在人机交互过程中,将自然语音转化为电子设备可处理文本的首要前提,是将模拟声波物理量转换为计算机可识别的连续数字流。具体而言,当终端接收到用户的语音输入指令(例如,通过点击屏幕UI界面的麦克风图标、触发特定的实体硬件按键,或通过设备底层的离线唤醒词激活)后,系统底层响应于该指令调用该终端本地的麦克风阵列,持续捕获外界的模拟声波信号。

[0041] 随后,终端底层的模数转换器(ADC)会对该模拟信号进行高频的采样、量化和编码。在本实施例中,为了在离线语音处理模块的“计算开销”与“声学特征保留度”之间取得较佳平衡,系统优选采用16000Hz(16kHz)的采样率、16-bit的位深以及单声道(Mono)格式,将模拟音频转化为脉冲编码调制(PCM)数字音频流。16kHz的采样率能够完整覆盖人类语音的核心频段,且数据体积适中,是绝大多数端侧深度神经网络进行声学特征提取的最佳输入格式。

[0042] 1.2 音频流的降噪与纯净化预处理策略

[0043] 考虑到用户在实际移动场景中往往处于地铁、街道、会议室等高噪或强混响的复杂环境,为确保后续异步双轨转写引擎的识别准确率,在获取数字音频流的过程中,必须对

其进行必要的降噪与回声消除 (AEC) 预处理。本发明实施例提供了一种自适应双轨降噪策略,系统可根据目标终端的硬件算力层级与底层开放权限,灵活调度以下处理机制:

[0044] 策略一:基于操作系统 (OS) 原生的软件级降噪。当所述终端为常规算力设备时,本系统直接调用终端底层操作系统封装的标准音频接口 (API)。例如,在基于Android或其他通用开源系统的开发架构下,系统通过挂载OS原生的软件声学预处理模块 (如系统级Noise Suppression (NS) 降噪算法与Acoustic Echo Canceled (AEC) 回声消除算法),在极低延迟下获取经过软件算法实时过滤的纯净音频流数据。

[0045] 策略二:直通特定终端底层的硬件级降噪 (BypassOS策略)。随着端侧智能硬件的飞速迭代,当前部分高性能智能终端在其内部不仅搭载了极高规格的多麦克风阵列 (用于声源定位与波束成形),更配备了专用于处理声学信号的独立数字信号处理器 (DSP) 或音频专属NPU。因此,在一个更优的实施例中,若本发明部署于上述顶级硬件终端,系统的音频获取模块将跳过常规的系统应用层 (Application Layer) 软件降噪封装,通过调用底层的硬件音频接口 (例如硬件抽象层HAL或低延迟音频通道),直接获取由该终端数字信号处理器 (DSP) 在硬件物理层级完成降噪的高保真音频流。此策略能获取到具有高信噪比的纯净语音数据,从而有效释放终端主CPU的运算资源,将算力留给后续的深度神经网络大模型进行离线推理。

[0046] 经过上述获取与纯净化预处理机制,系统在终端本地内存中成功建立了一条源源不断、且具备极高信噪比的PCM音频数字流通道。该通道直接向内存缓冲区持续泵入高质量的声学特征数据,为后续将要执行的音频动态切片以及异步双轨转写引擎,提供了高质量的数据基础。

[0047] 第二节 连续音频的动态切片与异步双轨分发策略

[0048] 2.1现有连续语音转写技术的技术局限性

[0049] 在深入探讨本发明的核心调度机制之前,有必要对现有连续语音转写技术的行业现状与物理局限进行客观剖析。目前,行业内主流的语音输入法系统在处理长篇连续语音时,均面临着明显的技术瓶颈:

[0050] 一方面,采用“云端大模型”的方案中,其持续音频流的上传高度依赖网络稳定性,且为保障云端高并发架构的系统可用性,通常在接口层面强制设置时长熔断机制,导致用户单次连续输出的内容上限大多被强制锁定在2至5分钟以内。

[0051] 另一方面,在少数尝试将模型本地化的“端侧离线方案”中,现有的端侧模型,其单次连续识别时长也往往被保守地限制在2分钟左右。一旦超过该阈值,系统便会强制切断录音或发生识别停滞。这种普遍存在的时长限制,使得现有技术根本无法满足诸如政企会议记录、深度访谈、长篇商业推演等动辄数十分钟甚至数小时的长篇高频输出场景。

[0052] 2.2端侧长音频推理的内存溢出问题分析

[0053] 上述端侧离线模型之所以无法进行长时间 (如一小时以上) 的连续语音输出,核心根源在于底层物理内存 (RAM) 溢出风险与处理延迟加剧。

[0054] 现代高精度语音识别模型 (尤其是包含注意力机制的大型深度神经网络) 的计算复杂度,会随着输入音频维度的增加呈非线性 (如平方级) 增加。如果将未经处理的超长音频流持续输入此类模型,系统需要在内存中维护极其庞大的声学特征矩阵与历史上下文状态。

[0055] 随着录音时间的推移,模型推理速度会发生显著下降,导致最终文本的“上屏延迟”越来越长,严重影响用户的交互体验。此外,当音频数据量超过智能手机等端侧设备的内存物理上

限时,必然引发严重的内存溢出(OOM)。这会导致输入法进程的异常终止,甚至会引发整个底层操作系统进程阻塞(或无响应)。

[0056] 2.3动态音频切片的优选实施机制

[0057] 为了有效解决上述技术瓶颈,本发明在系统前端引入了一套极其关键的动态音频切分预处理机制。系统在获取纯净化音频流的同时,将其注入低开销的环形缓冲区(Ring Buffer),并采用“双重阈值监测”策略来触发切分操作:

[0058] 条件一:基于语义连续性的软切分。系统调用极低功耗的声学端点检测(VAD)算法,对音频流进行实时帧级扫描。当检测到用户的语音停顿持续时间达到第一预设时间阈值(优选为500毫秒至800毫秒)时,系统判定当前语句暂告一段落,并在此静音处执行切分。此机制最大程度保障了自然语句的完整性。

[0059] 条件二:基于物理内存保护的强制硬切分。当用户处于极高语速的持续输出状态,或嘈杂环境导致VAD失效时,系统实时计算当前未切分音频的累计时长。一旦达到第二预设时间阈值(例如根据NPU算力优选为8秒至10秒),无论用户是否正在发音,系统均立即执行“强制硬切分”。这是杜绝OOM风险的有效物理底线。

[0060] 需要指出的是,尽管上述切片逻辑有效规避了内存溢出风险,但强制切分不可避免地会从物理层面切断某个完整的词汇,导致相邻切片在分别识别时产生首尾重叠的冗余“回音”。针对该副作用,本发明已设计了严密的边界去重(FuzzyMatch)逻辑,该部分将在后续章节进行详述。

[0061] 2.4异步双轨并发与基于状态驱动的动态内存生命周期管理

[0062] 在生成固定大小的音频数据块(音频切片)后,系统随即将该切片数据一分为二,并发分发至后续的第一级语音处理模块(快轨)与第二级语音处理模块(慢轨)。

[0063] 为了实现长达数小时的不间断运行,本发明在此处创新性地设计了“基于UI状态驱动的极简内存生命周期管理策略”:

[0064] 一级转写缓存的延时销毁:当快轨模型完成流式解码并输出临时草稿后,该草稿文本随即输出至显示区域。此时,该切片在一级缓存中的音频数据并不会立刻释放;而是在二级转写模型(慢轨)的高精度文本成功输出至显示区域、并完成对该草稿的平滑替换瞬间,系统底层才会触发指令,将该切片在一级转写工作空间中的所有残留缓存数据彻底释放,此举亦为极端情况下的推理降级容错保留了数据底座。

[0065] 二级转写缓存的接力释放:对于二级转写模型(慢轨)的缓存数据,当其完成高精度推理及在显示区域成功执行替换后,系统同样不会立刻释放其内存。这是因为系统需要保留其尾部特征数据,以便与下一个音频切片的头部进行边界去重比对。因此,只有当下一个相邻音频片段的二级转写内容在显示区域成功执行替换后,系统才会彻底释放前一个切片在二级转写空间中的所有深度推理缓存。

[0066] 通过上述精密的“接力式”内存释放策略,系统在任何时刻,其后台常驻内存中仅需维护极少量的(例如不超过3至5个)活跃音频切片数据。这种将空间复杂度从线性叠加转化为常数级开销的架构设计,有效消除了端侧大模型长时运行的OOM风险。此外,在实际的

商业化落地中,承载本发明架构的应用程序即使通过标准应用分发平台(如通用应用商店)下载安装,并在受限于终端操作系统(OS)严格后台内存管理机制的真实商用智能设备上运行,依然有效实现了连续2个小时以上、毫秒级响应的高精度连续语音推理与内容输出,且未发生任何内存溢出或被底层系统强行终结(Kill)的现象,这充分验证了本切片与内存调度架构的极高工程鲁棒性与工业实用价值。

[0067] 应理解,上述关于动态音频切片的具体参数(如500毫秒至800毫秒的静音阈值、8秒至10秒的强制切分阈值)以及一二级转写的特定缓存接力清除时机,仅为适配当前主流智能手机算力与内存规格的最优实施例。本领域技术人员可以根据目标设备的具体硬件生态条件(如不同的RAM容量、不同的NPU/CPU算力级别)以及特定应用场景,对上述切分时间阈值和生命周期释放节点进行灵活调整。这种基于“阈值切片以防溢出”以及“交替接力释放内存”的底层调度逻辑,作为本发明宏观异步双轨架构中密不可分的核心组成部分,均应有效落入本发明的保护范围之内。

[0068] 第三节 极速快轨的流式响应与硬件级异步并发调度

[0069] 在系统通过前述机制完成连续音频的动态切片后,切片数据将被同步分发至双轨处理管道。为保障双轨并发在端侧有限算力下的高效运行,本节将详细阐述第一语音处理模块(快轨)的模型选型、流式响应机制,以及至关重要的跨硬件协同调度策略。

[0070] 3.1跨硬件协同的异步并发与线程调度策略

[0071] 在端侧设备(尤其是智能手机)中并行运行两个语音处理模块,易引发底层计算资源的抢占与严重的设备发热(Thermal Throttling)。为了解决这一工程难题,本系统在分发音频切片时,引入了深度的硬件线程调度机制。实施者可根据目标设备的硬件生态,灵活采用以下两种并发策略:

[0072] 策略一:基于硬件降级回退的全局并发策略(兼容方案)。

[0073] 系统在下发计算任务时,设定硬件调用优先级为:NPU(神经网络处理单元)→GPU(图形处理器)→CPU(中央处理器)。当任务下发时,系统优先请求最高效的NPU或GPU算力;若设备不支持或硬件被占用,则自动降级交由CPU兜底执行。此策略的优势在于能够较好地兼容常规算力设备。但在实践中,实施者需注意:在极端缺乏NPU/GPU算力的低端机型上,强制由单核或多核CPU兜底执行双轨并发计算,可能会导致系统响应变慢。

[0074] 策略二:基于硬件解耦的“CPU+NPU”双轨专线调度策略(优选实施例)。

[0075] 针对当前普遍搭载NPU的智能终端,本发明提供了一种算力解耦的物理隔离策略。具体而言:系统将第一语音处理模块(快轨)的流式解码线程,强制分配给手机的中央处理器(CPU)执行;同时,将第二语音处理模块(慢轨)的深度推理线程,强制绑定至神经网络处理单元(NPU)执行。

[0076] 该策略的有益效果在于:第一语音处理模块的模型参数量较小,使用CPU运算能够实现低延迟响应;而第二语音处理模块的神经网络模型与NPU的张量运算特性相匹配。此举有效避免了快慢双轨在同一计算单元内的线程互相挂起与抢占,大幅降低了芯片的整体峰值功耗与发热量;更为核心的是,它充分调度并释放了智能终端日常处于极度闲置状态的NPU算力(该算力在常规文本交互场景下通常处于低负载状态),实现了硬件资源的完美错峰利用。

[0077] 应理解,上述硬件调度策略旨在说明本发明异步双轨架构的系统级优化潜力。在

实际应用中,实施者根据不同的芯片厂商平台提供的底层API,采用不同的硬件绑定组合(例如将慢轨绑定至特定DSP,或采用异构计算框架进行动态算力分配),均属于实现本发明宏观架构中“双轨并发”目标的等同手段,均应落入本发明的保护范围之内。

[0078] 3.2 第一语音处理模块的模型选型与极速响应使命

[0079] 在明确了底层硬件调度后,第一语音处理模块(快轨)的主要作用是实现“极低的视觉延迟反馈”。在模型选型上,本系统优选采用基于概率统计模型或轻量级神经网络模型的声学架构。具体而言,包括但不限于传统隐马尔可夫模型(HMM)、循环神经网络(RNN)、卷积神经网络(CNN),以及经过轻量化裁剪的纯自注意力流式解码网络模型(如微型Transformer或Conformer架构)。

[0080] 例如,实施者可采用开源社区中常见的轻量级流式语音识别框架(如VOSK的轻量化分支版本)。这些模型经过深度的参数量级压缩(其文件物理体积通常仅在40MB左右),具备极低的计算复杂度。当切片数据进入该模块(如上述的CPU专属线程)时,其能够利用流式解码算法实现极低延迟的增量式字符输出(即流式上屏)。在实际测试中,其上屏延迟可控制在数十至上百毫秒级别。这种近乎零延迟的“初始转录文本(草稿)”被快速输出至终端显示区域,有效避免了长音频输入过程中的界面无响应状态。

[0081] 应理解,本文所提及的“40MB 文件体积”或“开源轻量级框架”仅为方便说明极速快轨优势的举例。未来随着算法的演进,实施者采用任何其他参数量级极小、且能在极低延迟下生成初始转录文本的声学模型(或跨语种微型模型),作为填补视觉空白的先锋阵列,均应落入本发明“一快一慢”双轨交互架构的保护范围。

[0082] 3.3 关键缺陷的架构级容错与靶向高频词库干预

[0083] 尽管第一语音处理模块具备显著的速度优势,但由于其缺乏深度的上下文理解能力,在面对同音词或复杂长句时,存在识别精度受限的技术缺陷。为了在此缺陷下保证良好的交互体验,本发明采取了双重策略:

[0084] 策略一:架构级豁免(定位为视觉草稿)。在本发明的宏观架构中,该模块输出的文本在系统底层被明确标记为“视觉临时草稿”。系统并不强求其具备最终可用级别的准确率,因为这些文本在提供初始视觉反馈后,最终都将在界面(UI)层面被后续第二语音处理模块的高精度文本平滑替换。

[0085] 策略二:微型专属词库的靶向提效。为了防止初始草稿的识别错误率过高而引发较差的交互体验,本系统在第一语音处理模块中外挂了一个微型本地专属词库。在一个优选实施例中,该词库被严格控制在极小规模(例如2000个词汇以内),以确保不拖慢流式解码速度。这些词汇是预先利用外部高算力服务器上的超大语言模型(LLM)基于高频人类对话语料蒸馏(Distillation)提取出的“核心高频词汇”。在快轨执行转写时,该词库作为解码图(Decoding Graph)的权重增强节点被热加载,其能够在不增加算力负担的前提下,有效纠正轻量级声学模型易发的常规同音字或高频形近字错误,将其视觉准确率拉升至可接受的草稿水平。

[0086] 应理解,上述外挂微型词库的词汇数量上限(如2000个)、提取来源(如LLM蒸馏)或其在解码图中的具体权重加载算法,仅为进一步优化快轨视觉体验的优选实施手段。实施者通过变更词库规模、采用不同行业领域的专属草稿词典,或直接取消该微型词库而仅依赖架构级的替换来掩盖小模型的缺陷,均不脱离本发明核心架构的保护范围。

[0087] 第四节 慢轨深度推理与硬件资源的自适应调度策略

[0088] 在第一语音处理模块(快轨)以极低延迟完成临时草稿的流式上屏后,系统后台的第二语音处理模块(慢轨)正同步对相同的音频切片进行高强度的深层语义解析。本节将详细阐述慢轨模块的选型逻辑、延迟的物理溯源,以及针对不同硬件平台的算力自适应调度与交接机制。

[0089] 4.1第二语音处理模块的选型与深层语义解析

[0090] 针对第二语音处理模块,其主要作用是提供显著优于第一语音处理模块的高层级转录准确率,以有效修正快轨草稿中的同音词、上下文语境错误及专有名词识别异常。

[0091] 目前市面上符合该条件的端侧深度神经网络框架包括但不限于:基于Transformer架构的开源大模型(如Paraformer系列非自回归模型、Whisper系列端侧模型等)。

[0092] 作为本申请的一个优选实施例,为了更精准地提取音频特征,系统优选采用包含复杂多头注意力机制(Multi-Head Attention Mechanism)的深度神经网络模型。该机制能够精准捕捉长音频切片中前后词汇的上下文依赖关系,专门用于进行全局深层语义建模,从而实现极高精度的深层语义解码。

[0093] 4.2“第二响应延迟”的物理因果与客观现象

[0094] 本发明宏观架构中一个客观存在的系统特征是:第二语音处理模块输出最终文本的“第二响应延迟”大于第一模块的“第一响应延迟”。

[0095] 这一时间差的产生,通常具有底层的物理与数学依据。为了获取高精度的语义理解能力,第二语音处理模块的模型参数量及物理体积往往显著大于第一声学模型。庞大的参数矩阵意味着呈非线性增加的浮点运算量(FLOPs)。因此,即使系统调度了终端的高性能算力单元,第二语音处理模块完成一次完整切片的深度推理耗时,也大于第一语音处理模块的流式输出耗时。

[0096] 4.3终端硬件算力的自适应适配与量化(Quantization)策略

[0097] 由于本发明广泛应用于形态各异的终端设备,第二语音处理模块的加载策略并非一成不变,而是根据目标设备的物理内存与算力天花板进行自适应适配:

[0098] 对于具备充足供电与较大内存容量的计算设备(如搭载高性能显卡或处理器的计算机),处理复杂度相对较低的语音转写任务游刃有余。此时,系统可直接加载未经量化的全精度(如FP32或FP16)深度神经网络模型,以获取较高的转录准确率,而无需担忧线程阻塞。

[0099] 然而,当本方法应用于智能手机等移动终端时,若强行加载全精度大模型,庞大的参数矩阵将迅速占满移动CPU/NPU的处理线程,导致底层计算资源枯竭并引发严重的热节流(Thermal Throttling)效应。因此,在智能手机的应用场景中,系统优选引入深度量化(如INT8量化)的大模型版本,并建议将其物理文件体积严格控制在150MB以内。这一自适应量化策略,能够在极大地降低内存占用与线程负荷的同时,保留大模型对语音识别而言完全够用的注意力机制特征。而针对智能麦克风等边缘设备,则依据其内置DSP算力与极其有限的RAM空间,进行更深度的裁剪与适配。

[0100] 4.4异构算力交接:从张量推导到逻辑控制的优选实施例

[0101] 在执行第二语音处理模块的密集推理时,本发明在一个优选实施例中,设计了一

套跨芯片的异构算力交接机制。

[0102] 在实际工程执行中,智能终端的NPU或GPU等专用加速芯片主要负责执行大模型中极其密集的矩阵乘加运算(MACs)。当慢轨模型借助NPU算力完成声学特征到字符的解码,并输出“高精度原始第二转录文本”的瞬间,NPU的主要处理阶段即告完成。

[0103] 由于NPU并不擅长执行复杂的字符串比对、哈希搜索及内存逻辑跳转,此时,系统底层架构将触发一次“硬件算力交接”:系统将NPU输出的原始文本字符串,迅速回传并写入终端主控CPU的活跃内存空间中。随后,所有的文本干预动作(包括词库纠错、VIP热词替换),以及针对相邻音频切片的边界去重拼接(FuzzyMatch)逻辑,均交由擅长逻辑控制的CPU主导完成。这种NPU负责高密度张量运算,CPU负责复杂逻辑跳转与字符串处理的异构协同机制,有效优化了芯片的执行效率。

[0104] 应理解,本节所述关于“第二响应延迟”的物理成因、针对不同终端的量化适配规则(如手机端限制在150MB以内)、以及在优选实施例中所列举的“NPU推理后交接给CPU处理”的异构算力调度机制,仅为详细阐明本发明在特定硬件约束下如何实现较高能效的示例性说明。

[0105] 实施者在实际应用中,完全可以采用其他等效机制。例如,采用参数量相近但算法复杂度不同的两个模型来产生差异化的处理延迟;或者在算力高度集成的单一芯片架构(或未来的新型处理器架构)中,将推理与逻辑后处理统筹于同一个计算单元内完成。本发明的核心思想在于宏观的“基于处理时延差异的双轨交替与界面动态替换”交互闭环。因此,无论终端设备采用何种维度的量化压缩标准、加载何种特定的模型文件格式,亦无论其底层的并发线程、内存及运算器(如CPU、GPU、NPU之间)是如何进行具体的任务分配与算力调度的,只要其服务于该宏观双轨交互框架,均有效落入本发明的保护范围。

[0106] 第五节 内存级瀑布式文本后处理与切片边界平滑缝合策略

[0107] 当第二语音处理模块(慢轨)借助NPU算力完成深层推理,并交接给主控CPU后,CPU内存中获取的是一段高精度原始转录文本(定义为:一级草稿)。然而,受限于是端侧模型深度量化带来的特定领域精度衰减,以及强制音频切片带来的物理断层,该一级草稿仍可能存在局部瑕疵。本节将以“全英文语音输入与英文文本输出”为优选实施场景,详细阐述CPU如何在极短时间内,通过“瀑布式草稿演进”流水线,进行多层级的动态干预与无缝缝合。

[0108] 5.1 量化损耗的物理必然性与双维前置提示词(Prompt)注入

[0109] 在边缘计算场景中,将数百兆的全精度大模型进行深度量化(如INT8),有效换取了推理速度,但可能会导致特定长尾词汇的识别率下降。为了在推理源头缓解此问题,系统首先采用前置提示词注入(Prompt Injection)策略:

[0110] 静态场景提示词:当用户启动全英文转写时,系统底层会首先根据当前预先设定的垂直领域应用场景(如 Technology, Medical, Legal等),提取对应场景下最高频的英文核心词汇(例如100至200个英文单词),将其作为上下文提示(Context Prompt)注入到慢轨解码器中。这能在不增加NPU算力负担的前提下,有效引导大模型向特定领域的英文语义特征倾斜。

[0111] 快轨草稿反哺(动态提示词):鉴于系统采用异步并发架构,当慢轨开始推理时,第一语音处理模块(快轨)生成的临时文本依然留存于缓存中。系统将该快轨草稿作为动态提示词同步注入(或输入)至慢轨大模型。尽管快轨草稿精度有限,但其保留了当前切片的宏

观语境与发音轮廓,可进一步强化大模型的解码方向,实现双轨数据的深度耦合与互相增益。

[0112] 5.2基于哈希匹配的白名单基础筛查与00V异常打标(生成二级草稿)

[0113] 当NPU输出“一级草稿”后,由于纯文本数字流的内存占用极小,主控CPU可在极短时间内对其执行多轮流水线后处理。系统首先引入的是“本地基础词库白名单机制”。

[0114] 该白名单是一个较大规模的本地静态英文词典,涵盖数万个英语通用高频词汇与基础语法词(如we,are,beautiful等)。系统底层利用英文空格特征进行快速分词,并采用哈希搜索算法(Hash Algorithm)将一级草稿中的词汇与白名单进行快速比对。

[0115] 此步骤的主要作用并非纠错替换,而是异常筛查与打标:当扫描到某个转录单词未命中白名单(例如疑似识别错误或生僻专有名词“aegix”)时,系统在内存中为该词汇隐式标记一个00V(Out-Of-Vocabulary,未登录词/疑似异常)底层标签。而命中白名单的常规标准词汇,则维持常规状态。经过此轮高效率的哈希筛查,系统在CPU内存中输出了带有00V分类标签的“二级草稿”,为后续算法提供了明确的干预标识。

[0116] 5.3具备第一优先级的用户热词干预(生成三级草稿)

[0117] 在获取二级草稿后,系统进入具有较高干预权重的环节:VIP 用户自定义英文热词干预。这一层级的设计初衷,是为了赋予用户专属词汇(如特定公司名、内部代号)以较高的匹配与替换优先级,缓解大模型易将其纠正为标准英语的技术局限。

[0118] 干预范围与逻辑(全盘遍历与重点关注):在此环节,VIP热词干预机制无视二级草稿中词汇是否带有00V标签,对全段文本执行全面的扫描遍历。尽管系统会优先去比对那些带有00V标签的异常词,但其主要技术优势在于:它具备替换标准英语单词的优先权限。

[0119] 系统根据预设的权重分配逻辑(例如将用户热词的英文字符长度作为核心权重因子),实施动态调整容错率的匹配策略:

[0120] 小于等于3字符短词过滤机制(防误干预机制):若用户添加的热词长度小于或等于3个英文字母(如 and, go, ORG),系统限制该热词的干预逻辑生效。极短词汇在容错比对时具有较高的碰撞概率(例如,极易将正确的“orc”误替换为热词“ORG”),限制此类极短热词,是保障系统工程鲁棒性的核心安全栓。

[0121] 严格匹配模式(4至5字符的热词):当热词长度为4到5个字符时,系统采用“严格映射逻辑”。仅当二级草稿中的文本片段与目标热词完全命中时,才有效执行大小写规范化或格式替换。

[0122] 低度容错与强覆盖模式(6至10字符的热词):当热词长度大于5且小于等于10个字符时,系统实时计算二级草稿对应词汇与目标热词的Levenshtein 编辑距离。当该编辑距离小于设定的容错阈值时,触发替换机制。

[0123] 实施例证(优先替换标准词):若用户添加了热词Wonderfud(某特定品牌名),大模型在一级草稿中可能会将其误识别为标准英文单词Wonderful。在5.2节中,Wonderful命中了白名单,未被打上00V标签。然而,当VIP机制介入时,系统发现二级草稿中的Wonderful与热词Wonderfud的编辑距离处于极小阈值内。此时,优先级机制生效,系统不考虑Wonderful作为标准英语的常规属性,直接将其替换为Wonderfud。

[0124] 高度容错模式(大于10字符的长串热词/短句):只需二级草稿的字符序列与目标

长热词的相似度(或子序列重叠率)达到45%以上,系统判定模型可能出现识别错误,并直接用目标长热词对该片段进行覆盖替换。

[0125] 经过VIP热词的全局遍历与强干预后,系统生成了高度个性化的“三级草稿”。

[0126] 5.4垂直领域专属词库的定向兜底(生成四级草稿)

[0127] 获取三级草稿后,系统触发第三层级的垂直领域词库(如医疗、法律等较大规模的定制词典)兜底。

[0128] 为了有效节省移动端CPU的算力开销,避免专业生僻词库对日常高频英语造成大面积误判,垂直词库的干预逻辑采用了“定向扫尾”机制(算力剪枝):

[0129] 垂直词库不再进行全盘遍历,而是仅针对三级草稿中依然残留有OOV异常标签、且未被VIP热词处理过的孤立单词进行定向扫描。系统调用模糊匹配算法,仅对这些残留的未干预孤立词汇进行行业维度的深度推断与修复。纠错完成后,系统在内存中正式生成内容更准确且逻辑连贯的“四级草稿”。

[0130] 5.5消除物理硬切分副作用:相邻切片的FuzzyMatch边界去重拼接

[0131] 在完成上述“瀑布式打标与定向后处理”后,四级草稿面临最后一项架构级挑战——“切片回音”。由于前端执行了动态音频强制硬切分,一个完整的英文词汇或短语可能会被割裂在相邻的两个音频切片中。这会导致双轨模型在独立识别时,在切片接缝处生成重复的英文字符(例如,上一段结尾输出“I will go to New”,下一段开头输出“New York today”)。

[0132] 本系统在执行上屏替换前,强制对四级草稿介入边界去重逻辑:系统从内存中提取相邻上一音频切片所对应最终文本的“尾部字符序列”,以及当前切片(四级草稿)的“头部字符序列”;随后计算两者的字符重叠度。

[0133] 实施者提示:在具体的工程实施中,可灵活采用不同的字符串匹配算法来计算该重叠度,例如但不限于:最长公共子序列算法(LCS)、Levenshtein 编辑距离算法、或基于N-gram的模糊匹配算法。当重叠度满足预设条件(如发现“New”作为重叠特征)时,系统将自动剔除当前四级草稿头部字符序列中的冗余重复字符,完成切片的平滑拼接(有效拼接为“I will go to New York today”),从而输出最终可用于屏幕替换的定稿文本。

[0134] 5.6核心干预架构与算法参数的统一说明

[0135] 应理解,本节所详细阐述的“白名单异常打标 → VIP热词无差别强覆盖 → 垂直词库基于OOV标签的定向兜底”这一瀑布式草稿演进流水线,以及具体的字符长度安全栓、编辑距离计算规则和LCS拼接算法,仅仅是申请人为了实现高效交互与算力平衡,在特定环境(如英文语境)下提供的一个优选实施例。

[0136] 鉴于文本后处理算法与内存调度技术的多样化实现路径,实施者在实际应用中,完全可以根据不同的目标语言架构(如中文、日文等无需空格分隔的连续字符型语言)、不同的底层操作系统生态进行适应性调整。例如:将底层分词规则(采用结巴分词替代空格分词)、词长计算标准(将英文字母数量替换为汉字个数),以及异常标签(OOV)的具体数据结构进行等同替换。

[0137] 本发明的底层技术内核在于“针对异步双轨并发导致的瑕疵,在CPU内存中利用权限分级的词库机制执行瀑布式后处理,并对切片断点进行边界缝合”。因此,任何对上述打标逻辑、算法细节的等同替换、参数微调或语种切换,只要其宏观上服务于本发明的异步双

轨动态替换工作流,均应有效落入本发明核心架构的保护范围之内。

[0138] 第六节 基于时间戳的坐标锚定与UI底层平滑替换机制

[0139] 在主控CPU内存中完成前述多层次后处理与边界去重缝合后,系统获取了连贯的“最终定稿文本”。本节将详细阐述输入法底层服务(Input Method Service)如何跨越异步双轨的时间差,在终端显示区域精准锁定并有效抹除第一语音处理模块(快轨)生成的历史草稿,最终完成视觉层面的平滑替换。

[0140] 6.1异步时间差挑战与“时间戳-索引”双向锚定机制

[0141] 由于快慢双轨的执行存在客观的物理时间差(即第二响应延迟显著大于第一响应延迟),系统面临的技术难点是:当慢轨定稿准备上屏时,快轨生成的草稿文本已驻留在屏幕的某个位置。为了在复杂的文本编辑流中精准定位并抹除旧草稿而不影响用户其他文本,系统必须引入一套全局的追踪坐标系。

[0142] 本实施例创新性地采用了“全局时间戳(Timestamp)与屏幕字符索引(Index)双向锚定”机制:

[0143] 标识分发:早在系统前端执行动态音频切片时,底层架构即为该特定的音频切片生成一个全局唯一的初始时间戳(例如Timestamp_10:00:00.000)或唯一哈希ID。该切片的数据指针连同此时间戳,被同步并发分发给快轨与慢轨模块。

[0144] 快轨坐标注册:当第一模块(快轨)完成推理,将其生成的“一级草稿文本”输出至终端屏幕显示区域时,输入法底层服务会精确监听并记录这段草稿文本在当前操作系统文本框内所占据的准确字符位置区间(即起始字符索引与结束字符索引,定义为区间[Index_start, Index_end])。系统底层随即将该坐标区间与Timestamp_10:00:00.000 进行强绑定,并存入后台内存的动态映射表(Mapping Table)中。

[0145] 6.2定向唤醒与精确坐标检索

[0146] 当数秒后(例如 10:00:05),第二模块(慢轨)历经NPU推理与CPU多级后处理,生成了针对该切片的“最终定稿文本”。此时,替换调度模块将携带其初始绑定的Timestamp_10:00:00.000触发UI替换动作。系统通过查询内存映射表,利用该时间戳主键,检索出该切片对应的旧草稿当前在屏幕UI上所占据的精确坐标区间[Index_start, Index_end],为底层替换指令提供目标坐标。

[0147] 6.3执行文本替换:底层UI指令的调度与视觉平滑过渡

[0148] 在锁定精确坐标后,系统向操作系统底层发送替换指令。为了适应不同性能的终端设备并提升视觉平滑度,本发明优选提供两种底层的API调度执行方式:

[0149] 方式一:基于底层API的全量区域覆盖指令(高兼容性模式)。

[0150] 调用底层文本编辑 API,如在Android上调用 InputConnection.setComposingRegion 框定区域,随后调用commitText 接口;或调用deleteSurroundingText接口。系统向该特定的[Index_start, Index_end]坐标区间发送静默删除指令,将区间内的草稿字符予以删除,随后将第二语音处理模块的“最终定稿文本”写入该位置。

[0151] 方式二:基于内存Diff比对的差异抹除指令(防闪烁模式)。

[0152] 为避免全量删除长文本可能引发的屏幕UI局部轻微闪烁或重绘(Repaint)开销,在一个更优的实施例中,系统在发送UI指令前,会在后台内存中预先对“旧草稿文本”与“最终定稿文本”执行差异比对算法(Diff Algorithm)。系统仅提取两者之间真正发生字符变

化的差异节点,随后向操作系统底层发送针对具体错误字符的定向退格删除(Backspace)与新字符插入指令。

[0153] 通过上述基于时间戳的坐标制导与底层API调度,系统完成了文本置换。该过程在视觉上表现为“初始草稿平滑过渡为高精度文本”,有效实现了低视觉延迟的显示更新,构成了本发明的异步双轨动态替换 workflow 闭环。

[0154] 6.4 基于异步算力负载的动态仪表盘与 UI 状态联动交互机制

[0155] 由于本发明采用了异步双轨架构,第二语音处理模块(慢轨)的深度推理耗时客观上长于用户的发音耗时。在用户进行极高语速的长篇输出时,系统后台尚未完成高精度后处理的“待处理音频切片”会不可避免地产生队列积压。为了提升交互体验并保障最终输出文本的完整性,本发明在输入法UI层引入了“动态算力状态仪表盘”与“动态进度反馈与状态标识机制”。

[0156] 阈值触发的动态算力仪表盘:

[0157] 在用户持续录音的过程中,系统后台实时监控慢轨队列中的“待处理切片数量(即积压数量)”。系统设定了一个算力安全阈值(例如5个切片)。

[0158] 当待处理切片数量小于5时,说明当前终端算力充沛,慢轨替换速度能够紧跟快轨输出,此时UI界面不显示额外的算力提示;

[0159] 一旦用户语速过快导致待处理切片数量突破该阈值(如大于等于5),系统判定算力面临高负载,将立即在UI特定区域(如屏幕顶部中央)触发“算力仪表盘”,展示当前未处理的切片积压数字。此举旨在通过视觉反馈,提示用户当前算力处于高负载状态。

[0160] 麦克风结束后的动态进度反馈与“DONE”状态标识机制:

[0161] 当用户点击结束麦克风录音时,虽然快轨的初稿已全部上屏,但慢轨内存中通常仍有最后数个切片(例如2个)正在执行深度的后处理与FuzzyMatch缝合。

[0162] 若系统毫无提示,可能会导致用户在后台后处理未完成时,进行下一步交互(如点击外部宿主软件的发送、保存或换行),从而保留或输出带有瑕疵的初稿。为此,本发明在用户结束拾音的瞬间,在终端界面显著位置(如右上角)动态输出处理进度提示信息(例如倒计时或显示“精加工剩余切片数:2... 1...”),以提示用户暂缓操作。

[0163] 只有当后台引擎报告所有切片均已完成终极UI替换时,仪表盘才会闪烁显示处理完成的状态标识(如“DONE”或特定高亮图标),宣告最高精度文本已就绪。

[0164] 应理解,上述算力仪表盘的显示位置(如居中或右上角)、阈值触发的具体数字(如5个切片)、以及精加工结束时的“DONE”文案与倒计时UI动效,仅为结合异步双轨架构提供一种优选交互实施例。实施者可根据具体的APP视觉风格进行UI元素的设计变体。本发明的底层交互逻辑在于:“通过实时监测后台异步慢轨的切片处理队列积压量,在UI侧进行动态的视觉预警,并在录音结束后通过动态进度提示引导用户暂缓交互,直至慢轨队列清零后方输出最终状态标识。”任何基于后台处理队列状态驱动前台UI进度提示与状态联动的交互方法,均应属于本发明的保护范围。

[0165] 应理解,本节所详细阐述的“时间戳-索引映射表”记录机制、坐标区间检索逻辑,以及所列举的Android平台InputConnection相关API接口或Diff差异退格机制,仅仅是为了清晰说明本发明如何实现底层UI替换而提供的一个具体工程实施例。

[0166] 实施者应当明确,不同的智能终端操作系统拥有截然不同的底层文本交互协议

(例如,iOS/iPadOS平台中的UITextDocumentProxy接口体系,Windows平台中的 TSF (Text Services Framework) 文本服务框架等)。本发明的核心思想在于:“通过在前端分发具有唯一标识(如时间戳)的任务,记录快轨上屏的动态位置特征,并在慢轨后处理完成后利用该标识寻址并执行对应位置的文本替换”这一宏观的UI状态同步与寻址替换逻辑。因此,无论实施者在具体的工程开发中,针对何种操作系统平台、采用何种特定名称的底层框架API来执行“删除旧字、写入新字”的动作,只要其遵循了本发明所述的“异步时间差下的追踪与替换”核心框架,均应属于本发明的保护范围。

[0167] 第七节 离线工作站与离线大脑的宏观拓展架构

[0168] 前述第一节至第六节所详述的“异步双轨并发与内存级后处理替换”机制,其主要聚焦于麦克风实时拾音的交互场景(在此统称为“1.0实时转写架构”)。当用户在第三方排版或笔记软件中调用该1.0架构时,随着转写与动态替换的持续进行,用户最终将在本地设备上生成包含长文本的标准数据对象。

[0169] 为了全面完善离线语音处理的完整生态,本发明在1.0架构的基础上,进一步公开针对预先录制多媒体文件的“离线工作站(2.0架构)”,以及针对长文本进行全局后处理的“离线大脑(3.0架构)”宏观扩展方案。

[0170] 7.1离线工作站:多媒体文件的异步双轨批处理机制(2.0架构)

[0171] 在真实的商务或生产力场景中,用户往往需要处理预先录制好的长篇录音或视频文件。本发明提供了一种纯本地的离线工作站模式:

[0172] 文件导入与数字化解析:系统获取预先录制的本地多媒体文件(涵盖各类音视频封装格式),在底层剥离视频轨道并提取纯净数字音频流。

[0173] 异步批处理与“全局先验提示词”注入:针对超大体积的音频流,系统启动双轨并发批处理以缓解单模型算力瓶颈。首先,利用极低算力开销的第一语音处理模块对文件切片进行极速全局扫描,生成“全局初始粗糙草稿”;随后,系统将该全局草稿作为高置信度的上下文提示词,成批次地注入至第二语音处理模块的上下文编码层或解码器中。

[0174] 瀑布式后处理与文档输出:第二语音处理模块在接收到提示引导后执行深度推理,并沿用前述的瀑布式后处理与边界去重逻辑。最终,系统将处理完毕的文本自动排版导出为标准文本格式,供用户离线查阅。

[0175] 7.2离线大脑:引入端侧第三语言模型的全局深度后处理(3.0架构)

[0176] 由于动态切片机制在极少数极端边缘场景下仍可能导致长难句的语境轻微割裂,且生成的文本文档在段落逻辑连贯性上可能存在不足。为此,本发明进一步引入了“离线大脑”架构。

[0177] 该架构在终端本地额外部署了一个独立的端侧第三语言模型(该模型为纯文本大型语言模型,专门负责自然语言逻辑处理,不参与前置的语音声学解码)。

[0178] 兼容多源输入的全局纠错与重构:系统允许将1.0实时架构生成的文本或2.0离线工作站导出的文档,作为完整上下文输入给该第三语言模型。该模型将基于文档的全局宏观语境,对局部拼写错误、切片造成的语序不连贯进行语义修正。同时,其可根据自然语义转折,执行智能段落重构、提炼文档摘要,并对齐原始时间戳,最终输出具备规范排版格式的标准文档。

[0179] 应理解,本节所公开的2.0离线工作站批处理架构(特别是基于快轨反哺慢轨的全

局先验提示词注入机制),以及3.0离线大脑架构(引入独立端侧文本模型进行全局语义重构),在技术本质上构成了与1.0实时转写架构相辅相成、但又具备独立技术价值的独立发明构思。

[0180] 实施者在实际应用中,将上述实时转写、文件批处理与全局排版整合于单一的系统工作流中,或将其作为独立的功能模块分别部署于不同的智能终端(如独立的录音笔硬件与后处理软件端),均属于本公开的技术等同替换。

[0181] 第八节 承载离线双轨架构的电子设备与多维物理实施形态

[0182] 为了有效实现前述第一节至第七节所述的“1.0实时转写”、“2.0离线工作站”以及“3.0离线大脑”等方法与系统宏观架构,本发明还提供了一种高度集成的电子设备,以及相应的计算机可读存储介质。本节将阐述该电子设备的核心硬件底座、软件部署形态以及极具创新性的物理实体实施例。

[0183] 8.1电子设备的核心硬件底座与指令执行基础

[0184] 本发明所述的电子设备,在硬件架构层面上,有效包括:

[0185] 至少一个处理器:该处理器可以是中央处理器(CPU)、图形处理器(GPU)、神经网络处理单元(NPU)、数字信号处理器(DSP),或是上述处理器的异构协同组合阵列。其核心作用在于提供充足的本地算力,以驱动前述各级语音处理模块(快慢双轨)及端侧第三语言模型的离线推理。

[0186] 与前述至少一个处理器通信连接的存储器:该存储器包括但不限于随机存取存储器(RAM)与非易失性存储介质(ROM/Flash)。所述存储器中存储有可被处理器执行的计算机指令。当所述计算机指令被处理器调取并执行时,使得该电子设备能够在本地受控环境内完整地执行前述1.0、2.0或3.0架构下的音频切片、双轨调度、多级词库后处理、时间戳锚定及UI动态替换等全部核心步骤。

[0187] 8.2软件实施形态:独立应用分发与系统级深度集成

[0188] 在实际的商业化部署中,该电子设备所承载的计算机指令集,能够以极其灵活的软件产品形态存在:

[0189] 独立应用程序(App)形态:本系统可被封装为标准格式的移动端或桌面端应用程序。用户可通过通用的数字应用分发平台(如各大官方应用商店或网络服务器)将其下载、安装并运行于现有的电子设备中。在此形态下,本系统作为独立进程,在操作系统的应用层调用麦克风与本地底层算力。

[0190] 系统级底层服务(Native OS Service)深度集成形态:在一个更深度的实施例中,本发明的核心逻辑可被直接编译并“深度集成”至电子设备的操作系统(OS)底层(例如,作为系统默认的底层全局输入法核心框架,或内核级的语音处理守护进程)。在此形态下,本发明获得了极高的内存保活优先级与硬件调度权限,能够在任何第三方宿主应用(如备忘录、通讯软件、文档编辑器)中提供全局的平滑替换体验。

[0191] 8.3通用移动终端的复用部署(如智能手机、平板电脑)

[0192] 当所述电子设备表现为智能手机、平板电脑或便携式个人计算机(PC)等通用移动终端时,本发明作为纯软件级的系统逻辑,无需依赖任何额外物理加速外设。系统直接复用该通用终端现搭载的高性能 SoC(片上系统),通过前述的“CPU+NPU 异构并发调度策略”,有效调度并释放终端现存的算力资源,即可完成双轨并行转写与动态替换。

[0193] 8.4独立边缘算力节点:智能麦克风音频外设的物理隔离

[0194] 考虑到特定商业场景对数据绝对安全的较高要求,本发明提供了一种极具针对性的自有硬件实体实施例——高度集成了独立算力芯片的智能麦克风音频外设。

[0195] 在此形态下,该智能设备不再是传统的“被动拾音器”,而是作为一个具备独立算力的边缘计算节点。其主要工作流程如下:

[0196] 硬件级隐私物理隔离:该音频外设内部独立封装了微型处理器(CPU/DSP/NPU)与内置运行内存(RAM)。当用户发声时,在自身的硬件隔离环境中,独立完成音频动态切分、双轨语音转写推理、以及多级词库的深度后处理与边界拼接。

[0197] 文本数据的单向传输:该外设阻断了原始音频流或声学特征向宿主设备(如手机或电脑)的传输。它仅将最终生成的“定稿文本字符”,通过蓝牙(Bluetooth)、通用串行总线(USB)或HID(人机接口设备)等通用底层传输协议,单向传输至宿主设备的显示区域中。

[0198] 算力卸载与高度安全:在此架构下,宿主设备(手机/PC)的CPU/RAM有效降低了运算负担,且由于其从物理链路上无法获取用户的原始声音数据,从而提供了较高安全级别的隐私隔离。

[0199] 8.5跨设备扩展与计算机可读存储介质声明

[0200] 应理解,本节所列举的通用智能手机、平板电脑、PC以及带有独立算力的智能麦克风风外设,仅为说明本发明电子设备部署灵活性的若干优选物理形态。

[0201] 随着边缘计算、物联网(IoT)与可穿戴硬件的快速发展,实施者将本发明所述的指令集与架构,部署于智能手表、AR/VR空间计算眼镜、智能车载座舱主机等未知的物理形态载体中;或是通过分布式硬件协同执行本方法的各个步骤,均应属于本发明的保护范围。

[0202] 此外,本发明还提供一种包含指令的计算机可读存储介质(如光盘、硬盘、U盘、网络存储空间等),当其在计算机或智能终端上运行时,使得所述设备执行本发明上述的离线连续语音转写与动态替换方法。

[0203] 实施例 1:结合全英文交互场景的优选工程实施例

[0204] 为了使本领域技术人员更直观地理解本发明宏观架构在实际工程中的流转机制,以下结合一个具体的断网全英文输入场景,对前述的“异步双轨与内存瀑布后处理替换”全流程进行详细的过程展示。

[0205] 设定应用场景与核心参数

[0206] 目标终端与环境:搭载神经网络处理单元(NPU)的通用Android智能终端,处于完全断网的本地环境。

[0207] 模型选型:第一语音处理模块(快轨)采用开源VOSK轻量级流式声学模型;第二语音处理模块(慢轨)采用基于INT8深度量化的开源Whisper(WH)端侧大模型。

[0208] 词库设定:本地基础白名单预置了 Today, I, am, going, to, University, listen, professor, lecture 等大量高频通用英文词汇;用户自定义热词库中添加了专属词汇Harvard。

[0209] 用户发音行为:点击麦克风,连续说出以下英文:“Today I am going to Harvard University, (此处伴随约 600 毫秒的自然停顿) to listen to the professor’s lecture.”

[0210] 全流程执行步骤展示

[0211] 第一阶段:动态切片与全局时间戳分发(前端处理)

[0212] 当用户点击麦克风开始发声,系统底层持续获取纯净音频数字流。当用户说到“University”并发生停顿时,终端底层的VAD(声学端点检测)算法检测到了达到预设阈值(如600毫秒)的静音区间。系统在此处执行“软切分”,将该连续长句切分为两个独立的音频切片:

[0213] 针对首个被切分的切片数据 Slice_1 而言,其内部主要包含了前端的音频发音:“Today I am going to Harvard University”,系统为其生成并赋予全局时间戳 Timestamp_T0。

[0214] 针对紧随其后的第二个切片数据 Slice_2 来说,由于声学端点检测(VAD)算法设定的尾部平滑延迟及音频缓冲区的冗余设计,导致其包含了残余回音与后半句内容:“university to listen to the professor's lecture”,系统为其赋予全局时间戳 Timestamp_T1。

[0215] 第二阶段:第一片段(Slice_1)的双轨流转与首次全量上屏

[0216] 快轨坐标锚定:系统将Slice_1分发给快轨。VOSK模型极速流式解码,由于缺乏上下文,其将Harvard误识别为了harbor。

[0217] 此时显示区域率先输出临时草稿:“Today I am going to harbor university”。

[0218] 底层输入法服务精确记录了这段草稿在屏幕上的坐标区间,并与Timestamp_T0关联绑定。

[0219] 慢轨瀑布后处理:与此同时,慢轨Whisper语言模块正在调用NPU对Slice_1进行深度推理。由于检测到了句尾的自然停顿,Whisper语言模块触发了标点预测,并输出了带有量化误差的一级草稿“Today I am going to Harbard University.”(注意:末尾自动生成了句号)。随后,CPU介入执行瀑布后处理:错词Harbard被白名单打上OOV标签;用户自定义热词机制触发一级干预权重,实时计算编辑距离后,将Harbard替换为用户的专属热词Harvard。

[0220] 判定与首次全量替换:由于Slice_1是本次语音输入的“起始片段(Number One)”,其前方不存在任何历史音频,因此系统直接跳过边界去重(FuzzyMatch)逻辑,将其判定为定稿文本“Today I am going to Harvard University.”。

[0221] 替换调度中心携带Timestamp_T0锁定屏幕坐标,向底层发送全量覆盖指令。

[0222] 此时显示区域的变化:将原有的初始草稿全量删除,并平滑更新输出最新内容为:“Today I am going to Harvard University.”

[0223] 第三阶段:第二片段(Slice_2)的接力处理与上下拼接

[0224] 第二段快轨上屏:在处理Slice_1慢轨的数秒内,Slice_2的快轨也已快速完成流式输出,并在屏幕上第一句话的末尾自动追加了第二段的初始草稿“university to lisent to the professors lecture”(包含典型的快轨拼写与符号缺失特征)。

[0225] 在上述拼接处理完成后,此时显示区域的整体画面为:

“Today I am going to Harvard University. university to lisent to the professors lecture”。

[0226] 底层同样记录了第二段草稿的独立坐标区间,并绑定Timestamp_T1。

[0227] 慢轨推理与FuzzyMatch去重拼接:随后,慢轨对Slice_2完成推理,生成带有正确

拼写的文本：“university to listen to the professor’s lecture.”。在将其输出至显示区域前，系统提取前一个片段(Slice_1)缓存中的尾部特征与当前片段(Slice_2)的头部特征进行比对。系统识别出交接处的冗余字符 “university”，随即将Slice_2头部的冗余词剔除。最终生成Slice_2的拼接后定稿：“to listen to the professor’s lecture.”

[0228] 接力全量替换：系统携带Timestamp_T1锁定显示区域上第二段初始草稿的坐标，执行第二次底层的全量静默删除与新文本写入。

[0229] 第四阶段：视觉效果与显示区域呈现总结

[0230] 通过上述时序接力，用户在终端显示区域内能够观察到平滑的视觉替换过程：

[0231] 屏幕率先输出第一段初始草稿：“Today I am going to harbor university”

[0232] 该草稿被快速全量替换为带句号的高精度定稿：“Today I am going to Harvard University.”

[0233] 屏幕紧接着在句号后追加第二段初始草稿：“ university to lisent...”

[0234] 该后半句草稿再次被全量覆盖，替换为拼接后的定稿文本：“to listen to the professor’s lecture.”

[0235] 最终，基于真实的切片时序、大模型标点预测以及全量替换机制，显示区域内最终稳定显示的完整文字为：

[0236] “Today I am going to Harvard University. to listen to the professor’s lecture.”

[0237] 整个离线双轨动态替换架构，在此客观且完整地验证了端侧大模型结合物理切片后的真实工程状态。

[0238] 实施例工程现象特别说明：

[0239] 在上述最终呈现的文本(“Today I am going to Harvard University. to listen to the professor’s lecture.”)中，句中出现的额外句号，系第二语音处理模块在对第一切片(Slice_1)进行独立推理时，因捕捉到语音停顿而自动生成的客观标点特征。此为端侧大模型结合物理切片处理下的客观工程现状。

[0240] 针对该现象，实施者固然可以在后一个音频片段(Slice_2)定稿上屏前，引入跨切片的标点平滑算法予以消除。然而，此举将显著增加系统的底层控制与跨切片调度复杂度，具体原因如下：

[0241] 其一，自然语言中的标点符号种类繁多，合法性判定标准极高；

[0242] 其二，第一片段的文字及该标点符号已在此前完成了界面全量替换，并已稳定驻留于终端显示区域。若要跨切片删除该符号，系统必须重新逆向检索并定位第一片段尾部符号的精确屏幕坐标区间，并向操作系统额外下发一次底层的定向删除指令，此举会显著增加极速输入过程中的计算开销与UI重绘负担；

[0243] 其三(核心风险)，受限于端侧算力，当前模型尚无法完全精准甄别该标点是源自用户真实语音停顿(即具备实际语意转折逻辑的合法断句)，还是模型因音频物理切分而自行推断补充的冗余符号。

[0244] 综上，为了降低“误删有效标点”的工程风险，并保障整体UI替换框架的极简与鲁棒性，本实施例客观呈现了该现象。建议实施者在具体商业部署时，需结合特定语种习惯与模型标点预测倾向进行全局考量与深度测试，以妥善解决此类因物理切片引发的微小视觉

瑕疵。

[0245] 以上所描述的实施例仅为本发明技术构思的若干示例性实现,其提供具体而详细的描述,旨在充分公开本发明,而非以任何方式对本发明的保护范围构成限定。本发明的核心构思具有广泛的适用性。本领域普通技术人员在理解本发明核心构思与基本原理的基础上,能够对本文所述的技术方案进行各种形式的等效替换、修改、组合、改进或功能性扩展。凡是包含本发明核心技术特征,且在不脱离本发明精神与保护范围内的任何修改、变形或等效实现,均应被视为落入本发明所请求保护的范围之内。因此,本发明专利的实际保护范围最终将以所附的权利要求书及其等同物所界定。




图1